

Redes LSTM com custo CTC aplicadas à decodificação de digitação por gestos


Willians Cassiano de Freitas Abreu

Resumo

- Introdução
- Fundamentação Teórica
- Síntese e decodificação de gestos
- Experimentos e resultados
- Conclusão

Introdução


Definição do Problema



MARCO

Introdução

Definição do Problema




Justificativa

Fundamentação Teórica

Fundamentação Teórica

LSTM




Fundamentação Teórica

CTC



We start with an input sequence, like a spectrogram of audio.



The input is fed into an RNN, for example.

h	h	h	h	h	h	h	h	h	h
e	e	e	e	e	e	e	e	e	e
l	l	l	l	l	l	l	l	l	l
o	o	o	o	o	o	o	o	o	o
€	€	€	€	€	€	€	€	€	€

The network gives $p_t(a | X)$, a distribution over the outputs $\{h, e, l, o, \epsilon\}$ for each input step.

Fundamentação Teórica

CTC

h	e	€			€			o	o
h	h	e			€	€		€	o
€	e	€			€	€		o	o

With the per time-step output distribution, we compute the probability of different sequences

h	e			o
---	---	--	--	---


By marginalizing over alignments, we get a distribution over outputs.

$$P(w \mid G) = \sum_{A \in A_w} \prod_{t=1}^T p_t(c \mid G)$$

Fundamentação Teórica

Trie - FST


h	h	h	h	h	h	h	h	h	h
e	e	e	e	e	e	e	e	e	e
l	l	l	l	l	l	l	l	l	l
o	o	o	o	o	o	o	o	o	o
€	€	€	€	€	€	€	€	€	€



Síntese e Decodificação de Gestos


Decodificação

Bi-LSTM



Decodificação

Bi-LSTM + Trie



Síntese

Algoritmo

$w \leftarrow \textit{palavra}$

$K \leftarrow m(\omega_{c_i})$ para c_i em w

$O \leftarrow \mathcal{N}(K, s_1)$

$\theta \leftarrow \mathcal{N}(0, s_2)$

$V \leftarrow ((\mathbf{o}_{i+1} - \mathbf{o}_i)/2)R(\theta) + \mathbf{o}_i$ para i de 1 até $|O| - 1$

$Z \leftarrow \textit{interleave}(O, V)$

$G \leftarrow mjt(Z_i, Z_{i+1}, Z_{i+2})$ para i de 1 até $|Z| - 2$, com passo 2

Síntese

Algoritmo

$w \leftarrow \text{palavra}$

$K \leftarrow m(\omega_{c_i})$ para c_i em w

$O \leftarrow \mathcal{N}(K, s_1)$

$\theta \leftarrow \mathcal{N}(0, s_2)$

$V \leftarrow ((\mathbf{o}_{i+1} - \mathbf{o}_i)/2)R(\theta) + \mathbf{o}_i$

$Z \leftarrow \text{interleave}(O, V)$

$G \leftarrow \text{mjt}(Z_i, Z_{i+1}, Z_{i+2})$ para



passo 2

Síntese

Algoritmo

$w \leftarrow \text{palavra}$

$K \leftarrow m(\omega_{c_i})$ para c_i em


$O \leftarrow \mathcal{N}(K, s_1)$

$\theta \leftarrow \mathcal{N}(0, s_2)$

$V \leftarrow ((\mathbf{o}_{i+1} - \mathbf{o}_i)/2)R(\theta) + \mathbf{o}_i$ para i de 1 até $|O| - 1$

$Z \leftarrow \text{interleave}(O, V)$

$G \leftarrow mjt(Z_i, Z_{i+1}, Z_{i+2})$ para i de 1 até $|Z| - 2$, com passo 2



Síntese

Minimum Jerk Trajectory

$$C = \frac{1}{2} \int_{t_0}^{t_f} \left[\left(\frac{d^3 x}{dt^3} \right)^2 + \left(\frac{d^3 y}{dt^3} \right)^2 \right] dt$$

Síntese

Algoritmo

$w \leftarrow \text{palavra}$

$K \leftarrow m(\omega_{c_i})$ para c_i em


$O \leftarrow \mathcal{N}(K, s_1)$

$\theta \leftarrow \mathcal{N}(0, s_2)$

$V \leftarrow ((\mathbf{o}_{i+1} - \mathbf{o}_i)/2)R(\theta)$

$Z \leftarrow \text{interleave}(O, V)$

$G \leftarrow mjt(Z_i, Z_{i+1}, Z_{i+2})$ para i de 1 até $|Z| - 2$, com passo 2



— 1

Decodificação

Extração de características



Proposta Original (Alshariff et al.)

Decodificação

Extração de características



Nossa Proposta

$$X_{i,t} = P(\omega_i \mid g_t)$$

$$P(\omega_i \mid g_t) = \frac{1}{e^{\|m(\omega_i) - g_t\| \delta}}$$

Experimentos e Resultados


Resultados

Avaliação

Método de <i>decoding</i>	acurácia
argmax	65.51%
Trie	96.95%
Trie-3	97.76%

Experimentos



Reconhecimento de Palavras



- Exemplo de trajetórias para a palavra **ATTIC**. No exemplo à esquerda, o modelo decodifica corretamente. Já no caso a direita, à palavra identificada foi **SATIN**.

Experimentos


Reconhecimento de Palavras



- Exemplo de trajetórias para a palavra **DUMBNESS**. No exemplo à esquerda, o modelo decodifica corretamente. Já no caso à direita, a palavra identificada foi **DIMNESS**.

Experimentos

Transfer Learning para o Português



- Exemplo de trajetórias para a palavras em português corretamente classificadas. Em sentido horário, começando acima à esquerda: PROPOSTA, ORDEM, PAPEL e NORTE.

Experimentos

Comparação

Tabela 2 – Comparação com *baseline*

	ALSHARIF et al.	Nosso modelo
Dimensão LSTM	400	512
Número de parâmetros	1.5m	2.2m
Extração de características	Não	Sim
Palavras Únicas	8k	62k
Dataset de treino	124k	150k
Dataset de teste	14k	12k
Acurácia (%)	93.5	96.9

Conclusão e Trabalhos Futuros

Obrigado